

# Previsão de Autonomia Elétrica e Análise de Estações de Carregamento

Global Solution - 3ECR | Alunos

- Daniel Kramer de Holleben Santos | RM: 94277
- Rafaela Hitomi Osugi | RM: 95062
- Luana Domingos Dias | RM: 93191

Sumário

- 1. Introdução ..... 3
- 2. Descrição do Problema ..... 3
  - 2.1 Previsão de Autonomia Elétrica ..... 3
  - 2.2 Análise de Estações de Carregamento ..... 4
- 3. Metodologia Utilizada ..... 4
  - 3.1 Machine Learning: Previsão de Autonomia Elétrica ..... 4
  - 3.2 Visão Computacional: Análise de Estações de Carregamento ..... 5
- 4. Resultados Obtidos..... 6
  - 4.1 Resultados do Machine Learning ..... 6
  - 4.2 Resultados da Visão Computacional ..... 6
  - 4.3 Visualizações..... 6
- 5. Conclusões ..... 7
- 6. Próximos Passos ..... 7
- 7. Anexos ..... 8

## 1. Introdução

Com a crescente popularidade dos veículos elétricos (EVs), os desafios relacionados à sua adoção têm aumentado. Fabricantes enfrentam dificuldades em prever com precisão a autonomia elétrica, enquanto gestores de infraestrutura precisam lidar com a manutenção e o monitoramento de estações de carregamento. Esses problemas impactam diretamente a confiabilidade dos consumidores e a eficiência operacional.

Este projeto propõe uma solução integrada que combina **Machine Learning (ML)** e **Visão Computacional (CV)**, desenvolvida com o objetivo de:

1. Prever a autonomia elétrica de veículos de forma precisa.
2. Automatizar a análise de imagens de estações de carregamento, identificando falhas estruturais e elementos relevantes.

## 2. Descrição do Problema

### 2.1 Previsão de Autonomia Elétrica

A autonomia elétrica de um veículo é influenciada por múltiplos fatores, como:

- Ano de fabricação.
- Fabricante e tipo de veículo.
- Preço base e localização geográfica.

Estimativas imprecisas afetam:

- **Fabricantes:** Que precisam planejar melhorias nos modelos.
- **Consumidores:** Que buscam confiança na autonomia oferecida.

## 2.2 Análise de Estações de Carregamento

À medida que a infraestrutura cresce, monitorar manualmente as estações torna-se impraticável. Fatores como:

- Desgaste físico.
- Obstruções nos conectores.
- Falhas nos cabos e painéis, requerem uma análise automatizada para aumentar a eficiência.

## 3. Metodologia Utilizada

O projeto foi dividido em duas frentes principais: **Previsão de Autonomia Elétrica** e **Análise Visual das Estações de Carregamento**.

### 3.1 Machine Learning: Previsão de Autonomia Elétrica

#### 1. Coleta e Pré-processamento de Dados:

- Dataset: Inclui informações como:
  - Ano do Modelo (Model Year).
  - Fabricante (Make).
  - Tipo de Veículo Elétrico (Electric Vehicle Type).
  - Autonomia Elétrica (Electric Range).
  - Preço Base (Base MSRP).
- Tratamento de Dados:
  - Remoção de valores nulos.
  - Codificação das variáveis categóricas (Make, Electric Vehicle Type) usando LabelEncoder.

#### 2. Divisão dos Dados:

- Divisão em 80% para treino e 20% para teste, utilizando `train_test_split`.

### 3. Modelagem:

- Modelo utilizado: RandomForestRegressor.
  - Configurações: 100 árvores de decisão, random\_state=42.
  - Justificativa: Alta precisão em problemas de regressão e robustez para dados mistos.

### 4. Avaliação do Modelo:

- Erro Quadrático Médio (MSE): 94.75
- Coeficiente de Determinação ( $R^2$ ): 0.99

## 3.2 Visão Computacional: Análise de Estações de Carregamento

### 1. Processamento de Imagem:

- Imagens das estações foram carregadas e convertidas para escala de cinza usando cv2.COLOR\_BGR2GRAY.

### 2. Detecção de Bordas:

- Algoritmo utilizado: **Canny**.
  - Reduz o ruído com suavização (filtro Gaussiano).
  - Detecta bordas fortes e fracas em um processo de dois limiares.

### 3. Visualização:

- As bordas detectadas foram exibidas com Matplotlib, destacando elementos relevantes como painéis, conectores e cabos.

## 4. Resultados Obtidos

### 4.1 Resultados do Machine Learning

- **Desempenho do Modelo:**
  - **MSE:** 94.75
  - **R<sup>2</sup>:** 0.99
  - O modelo demonstrou excelente precisão na previsão da autonomia elétrica, sendo capaz de fornecer estimativas confiáveis para fabricantes e consumidores.

### 4.2 Resultados da Visão Computacional

- O módulo de Visão Computacional processou imagens com eficiência, identificando contornos e bordas relevantes.
- As estruturas das estações foram claramente detectadas, permitindo o monitoramento automatizado para manutenção preditiva.

### 4.3 Visualizações

- **Distribuição de Autonomia Elétrica:**
  - Histogramas mostraram a consistência dos dados analisados.
- **Imagens Processadas:**
  - A detecção de bordas destacou os elementos estruturais das estações de carregamento.

## 5. Conclusões

### 1. Previsão de Autonomia Elétrica:

- O modelo de Machine Learning desenvolvido apresentou alta precisão e desempenho, podendo ser utilizado para melhorar a confiança dos consumidores e otimizar decisões de mercado para fabricantes.

### 2. Análise de Estações de Carregamento:

- A integração com Visão Computacional automatizou a análise de imagens, destacando elementos estruturais e identificando possíveis falhas.

### 3. Impacto Geral:

- A solução é escalável e pode ser aplicada em larga escala, auxiliando fabricantes, consumidores e gestores de infraestrutura.

## 6. Próximos Passos

### 1. Aprimoramento do Modelo de Machine Learning:

- Experimentar com algoritmos mais avançados, como Gradient Boosting e XGBoost.
- Adicionar variáveis como condições climáticas e padrões de uso.

### 2. Expansão da Visão Computacional:

- Incorporar Redes Neurais Convolucionais (CNNs) para análise em tempo real.
- Detectar danos estruturais específicos, como rachaduras e desgastes.

### 3. Integração de Dados em Tempo Real:

- Utilizar sensores IoT para monitoramento contínuo das estações de carregamento.

## 7. Anexos

- **Código-Fonte:**

- Implementação detalhada disponível no arquivo Python anexado. [Github](#)

- **Resultados Visuais:**

- Histogramas de distribuição de autonomia elétrica.
- Imagens com bordas detectadas usando o algoritmo Canny.

- **Métricas do Modelo:**

- **MSE:** 94.75
- **R<sup>2</sup>:** 0.99